

In-depth Imagerie

Segmentation d'image et Estimation de pose

Axel Carlier

ISAE-SUPAERO, Département d'ingénierie des systèmes complexes (DISC)

axel.carlier@isae-supero.fr

2026

1 Segmentation d'image

2 Estimation de pose

ou *Image Parsing*




Objectif : Classification n-aire des pixels de l'image.

Une annotation extrêmement coûteuse :



plus de 300K images, et plus de 2,5M d'instances d'objets segmentés (plus de 22 heures-humain pour 1000 segmentations)

[Lin et al.] Microsoft COCO: Common Objects in Context.



11 millions d'images, plus d'un milliard d'instances segmentées.

[Kirillov et al.] Segment Anything



Un grand nombre de prédictions : une pour chaque pixel de l'image.

Les défis de la segmentation




La prédiction pour un pixel donné nécessite une analyse d'information locale conjointe à une compréhension plus globale de la scène.



Inconvénients :

- Très coûteux.
- Pas de prise en compte de l'image globale.


Fully Convolutional Networks (2014)



- Premier algorithme à implanter une segmentation *end-to-end*.
- Repose sur une reformulation des réseaux entièrement convolutifs.
- Base VGG-16.

[Long et al.] Fully Convolutional Networks for Semantic Segmentation.

Fully Convolutional Networks (2014)



- Résultat affiné en prenant en compte des prédictions intermédiaires.

[Long et al.] Fully Convolutional Networks for Semantic Segmentation.

Déconvolution (convolution transposée)





Image de https://github.com/vdumoulin/conv_arithmetic

- Chaque pixel porte une fonction `softmax` afin de déterminer quelle classe est la plus probable.
- On utilise l'entropie croisée pour comparer la classe prédite d'un pixel et la classe réelle.
- La fonction de coût finale est la moyenne des entropies croisées sur l'ensemble des pixels de l'image.

Cette fonction est particulièrement sensible au déséquilibre de classe !


UNet (2015)



- Une évolution de FCN.
- Probablement un des réseaux les plus utilisés pour la segmentation !

[Ronneberger et al.] U-Net: Convolutional Networks for Biomedical Image Segmentation.



UNet (2015)



Architecture adaptable avec n'importe quelle base convolutive !


[Ronneberger et al.] U-Net: Convolutional Networks for Biomedical Image Segmentation.

Vision Transformers (ViT)




[Dosovitskiy 2020] An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale

Vision Transformers : pré-entraînement non



[He 2021] Masked Autoencoders Are Scalable Vision Learners

Segment Anything



- Pré-entraînement de l'encodeur à l'aide de MAE, entraînement du modèle complet sur la base de données SAM
- Intégration de la possibilité de prompter le modèle avec différentes entrées (segmentation interactive)
- Fonction de coût : une combinaison linéaire de la *focal loss* et de la *Dice loss*

<https://aidemos.meta.com/segment-anything/gallery/>

[Kirillov et al.] Segment Anything

1 Segmentation d'image

2 Estimation de pose

Keypoints Challenge MSCOCO 2019



200000 images, 250000 personnes, 1,7M de joints.

Problème de localisation des "joints", ou articulations, d'une personne sur une image.




Nombreuses applications : reconnaissance d'actions, animation, jeux (Just Dance), *sports analytics*, etc.

Difficulté : prédictions locales mais nécessité d'une compréhension globale de la scène (comme pour la segmentation)

Estimation de pose


Approche "classique" implantée dans la Kinect (2011) :



Segmentation par parties du corps (forêts aléatoires) puis estimation de mode (*mean-shift*) pour l'extraction des joints.

[Shotton et al.] Real-Time Human Pose Recognition in Parts from Single Depth Images


DeepPose (2014)



Utilisation d'AlexNet comme base convolutive, prédiction directe des coordonnées des joints.

[Toshev et al.] DeepPose: Human Pose Estimation via Deep Neural Networks

DeepPose (2014)



Affinage de la prédiction en repassant une sous-région de l'image dans le réseau de neurones.

[Toshev et al.] DeepPose: Human Pose Estimation via Deep Neural Networks

Une idée introduite en 2015 consiste à prédire des cartes de chaleur pour chaque joint plutôt qu'une position.



Le problème se rapproche alors d'un problème de segmentation.


[Tompson et al.] Efficient Object Localization Using Convolutional Networks

OpenPose (2016-2018)


Convolutional
Pose Machines
(T -stage)

P Pooling
C Convolution


(a) Stage 1





(b) Stage ≥ 2



(c) Stage 1



(d) Stage ≥ 2




(e) Effective Receptive Field

Affinage des prédictions en prenant en compte des premières versions des prédictions.

[Wei et al.] Convolutional Pose Machines

OpenPose (2016-2018)




Les joints estimés avec certitude servent d'*a priori* aux joints pour lesquels il existe une ambiguïté.

[Wei et al.] Convolutional Pose Machines



(a) Input Image



(b) Part Confidence Maps


(c) Part Affinity Fields



(d) Bipartite Matching



(e) Parsing Results



Estimation conjointe des probabilités de présence des joints, et d'un champ de vecteur permettant dans une phase de post-traitement de connecter les joints.

[Wei et al.] OpenPose: Realtime Multi-Person 2D Pose Estimation using Part Affinity Fields

Institut Supérieur de l'Aéronautique et de l'Espace

10 avenue Édouard Belin – BP 54032

31055 Toulouse Cedex 4 – France

Phone: +33 5 61 33 80 80

www.isae-superaero.fr